CERITA MEMBANGUN AI UNTUK TAMBANG

Akurasi 93% di uji pertama. Saat diuji dengan bahasa lapangan, turun ke 61%.

Apa yang salah, bagaimana saya memperbaikinya, dan 3 pelajaran untuk siapa pun yang membangun asisten AI.

PROYEKNYA

Satu asisten AI, empat pekerjaan di tambang

K3 & SOP

Tanya prosedur

"Berapa radius aman peledakan?" → dijawab dari dokumen SOP, lengkap dengan sumbernya.

Insiden

Nilai risiko

Laporan kejadian → kategori bahaya, tingkat risiko, dan tindakan segera.

Produksi

Baca laporan shift

Pesan WhatsApp bebas → data rapi: OB, batubara, stripping ratio, unit rusak.

Maintenance

Diagnosa alat berat

"Mesin panas saat menanjak" → kemungkinan penyebab dan langkah perbaikan.

Data uji: dokumen & perusahaan fiktif

Geser →

UJIAN PERTAMA

93%

jawaban benar. Kelihatannya hampir sempurna.

Masalahnya: soal ujiannya memakai kalimat yang **hampir sama persis** dengan isi dokumen.

ISI DOKUMEN SOP

"Jalan angkut saat basah/licin — kecepatan maksimum 25 km/jam"

SOAL UJIAN PERTAMA

"Berapa batas kecepatan dump truck di jalan angkut saat basah atau licin?"

Ibarat ujian sekolah yang soalnya **disalin dari buku catatan**: menghafal kalimat sudah cukup untuk lulus.

Geser →

UJIAN YANG JUJUR

Saya tulis ulang 115 pertanyaan seperti orang lapangan bertanya

BAHASA LAPANGAN

"bro kalo jalan hauling lagi licin, DT boleh lari brp?"

SKENARIO

"Tensi operator 165/95 saat cek awal shift. Boleh mengemudi?"

JAWABANNYA TIDAK ADA DI DOKUMEN

"Berapa kapasitas tangki solar dump truck?" → AI harus berani bilang **tidak tahu**

Hasilnya, jawaban benar:

61%

Geser →

MENCARI BIANG MASALAH

Ternyata AI-nya menemukan jawabannya, tapi menolak menjawab

96%

pertanyaan: dokumen yang benar **berhasil ditemukan**

29%

pertanyaan yang sah **ditolak** sebagai "di luar topik"

Penyebabnya filter penjaga topik. Ambang batasnya saya **tebak sendiri** (0,45), dan ternyata terlalu ketat.

Pencariannya sudah baik. Yang rusak justru penjaga pintunya.

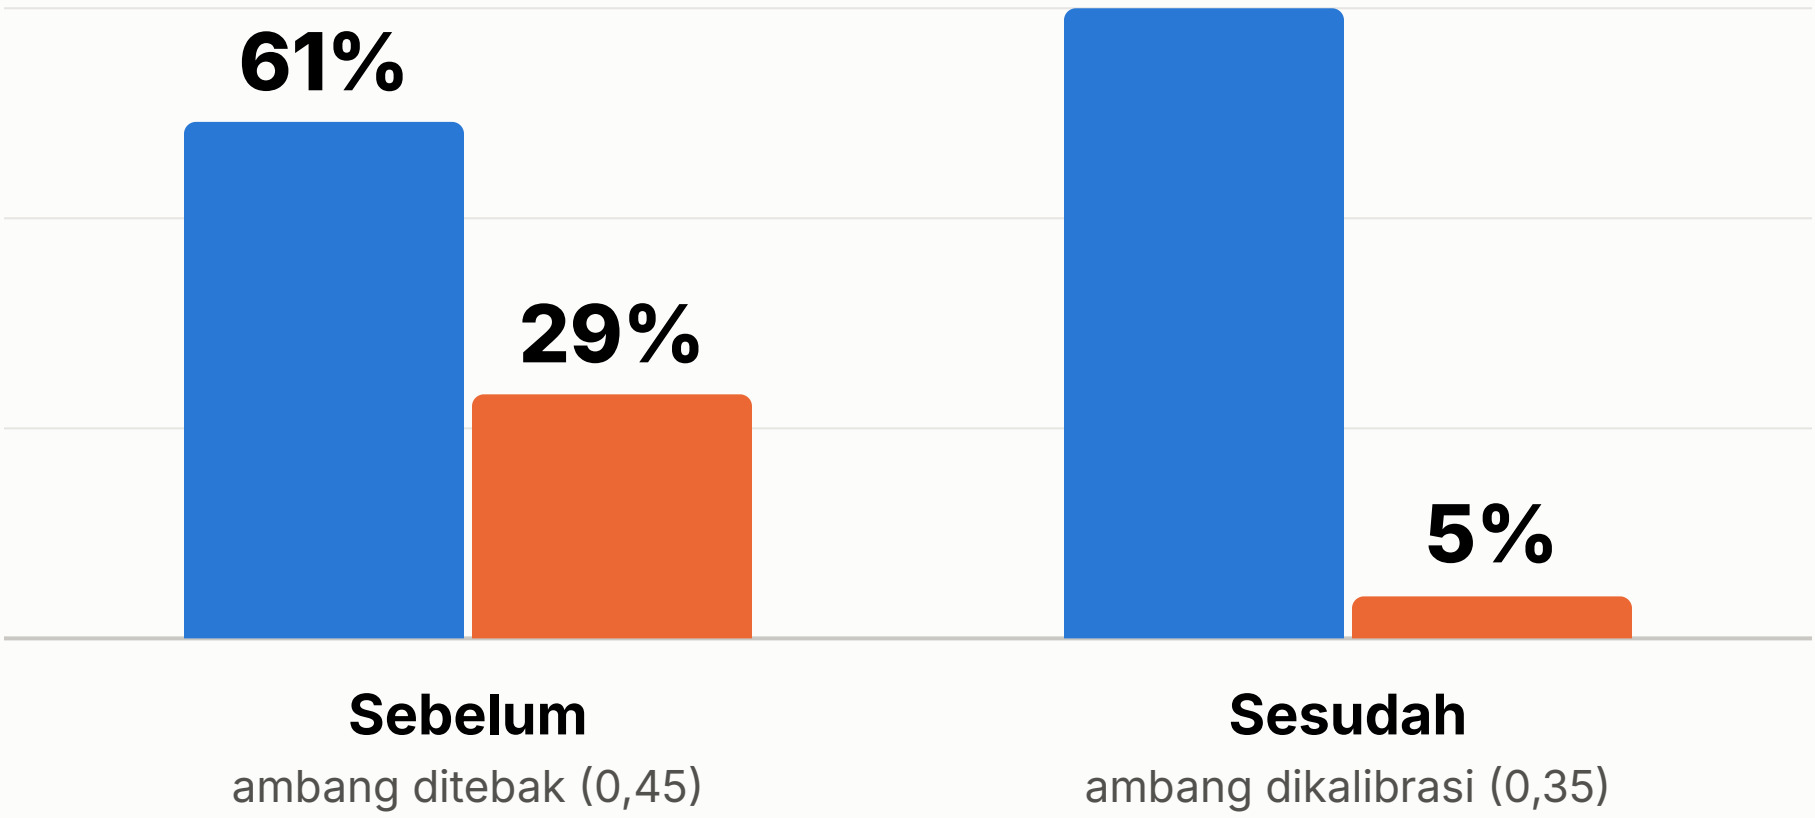
Geser →

PERBAIKANNYA

Ambang tidak ditebak lagi, tapi diukur dari data

Dikalibrasi memakai kumpulan pertanyaan **terpisah** dari soal ujian, supaya hasilnya tidak "curang".

Jawaban benar Ditolak padahal jawabannya ada



Interval kepercayaan 95%: 61% [51–72] → 75% [67–84], tidak tumpang-tindih

Geser →

TAPI SELALU ADA HARGANYA

Filter yang lebih longgar membuat sebagian pertanyaan di luar topik ikut lolos

10/10

pertanyaan di luar topik ditolak **sebelum** kalibrasi

8/10

sesudah kalibrasi: "tips diet" & "terjemahkan ke bahasa Jepang" lolos

Saya memilih trade-off ini dengan sadar: 14 poin lebih banyak jawaban benar untuk pekerja tambang, dengan risiko 2 pertanyaan iseng dijawab ngawur.

Trade-off seperti ini tidak akan pernah terlihat kalau tidak diukur.

Geser →

3 PELAJARAN

Yang akan saya lakukan sejak hari pertama di proyek AI berikutnya

1 **Uji dengan bahasa pengguna asli**
Soal yang mirip dokumen menghasilkan angka yang terlalu bagus untuk dipercaya.

2 **Jangan menebak angka penting**
Ambang, batas, dan parameter: kalibrasi dari data, di data yang terpisah dari data uji.

3 **Kunci kualitas di CI**
Setiap perubahan kode diuji ulang otomatis. Kalau akurasi turun, deploy dibatalkan.

Geser →

DI BALIK LAYAR

Dibangun end-to-end, terbuka untuk dipelajari

Python · FastAPI · Streamlit · RAG hybrid: BM25 + embedding · Reranker multilingual · scikit-learn · Pipeline fine-tuning QLoRA · Docker · GitHub Actions · 47 tes otomatis

Kode lengkap

github.com/srarykurniawan/minesense-ai

Bagaimana cara Anda menguji sistem AI supaya hasilnya jujur? Ceritakan di kolom komentar.